# TP — Prédire le mot suivant avec des bigrammes (n=2)

## Objectif : construire une petite aide à la saisie

Un utilisateur commence à écrire une phrase. Nous voulons proposer le mot suivant en utilisant les suites observées dans un petit corpus sur une sortie culturelle.

Le traitement suit cinq étapes : **phrases → tokens → bigrammes → comptes et probabilités → prédiction**.

Avec n=2, un événement comprend **un token de contexte et un token cible**. Le modèle utilise donc uniquement le dernier token saisi. Nous estimons les probabilités par comptes.

Règles :

1. Tokeniser la saisie.
2. Prendre son **dernier token seulement** comme contexte.
3. Si la saisie ne contient aucun token, utiliser DEBUT.
4. Calculer la distribution du contexte.
5. Trier par probabilité décroissante, puis chaîne lexicale croissante en cas d'égalité.
6. Retourner les 3 meilleurs couples ; si la distribution est vide, retourner une liste vide.

## Tester et interpréter

Utiliser les saisies fournies dans le JSON :

- `le guide prépare` ;
- `la classe prépare` ;
- `le musée propose` ;
- `le musée` ;
- `astronaute` ;
- une chaîne vide : `""`.

Pour chacune, afficher le contexte retenu, le top-3 avec ses probabilités et la meilleure prédiction. En l'absence de résultat, afficher **« Aucune prédiction : contexte non observé. »**